

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I INFORMACIJSKIH
TEHNOLOGIJA OSIJEK

Sveučilišni studij računarstva

REKONSTRUKCIJA SLIKA MAGNETSKE REZONANCE PUTEM
FASTMRI BIBLIOTEKE

Obrada slike i računalni vid

Dražen Bertić

Osijek, 2023.

Sadržaj

1	Uvod	2
2	Pristup	3
2.1	Magnetska rezonanca (MRI)	3
2.2	Tehnike rekonstrukcije	3
2.3	fastMRI	4
2.3.1	fastMRI dataset	4
2.3.2	fastMRI biblioteka	5
2.3.3	fastMRI repozitorij	5
3	Opis rada modela	6
3.1	<i>Zero-Filled</i> metoda	6
3.2	<i>Compressed Sensing</i> metoda	6
3.3	U-Net model	6
3.4	End-to-End VarNet model	7
4	Testiranje	10
4.1	Prikaz podataka	10
4.2	Testiranje modela	12
4.2.1	Simulacija šuma	12
4.2.2	Usporedba rezultata	12
4.2.3	Prikaz rezultata nad testnim podatcima	14
5	Zaključak	17
6	Literatura	18

1 Uvod

Medicinska dijagnostika je proces identifikacije i određivanja bolesti ili zdravstvenog stanja kod pacijenta. To uključuje korištenje različitih metoda, tehnika i testova kako bi se postavila ispravna dijagnoza i najbolji plan liječenja. Obavlja se u različitim medicinskim disciplinama, a moderne tehnologije i napredak znanosti omogućuju sve precizniju dijagnostiku. Zbog svojih sposobnosti stvaranja detaljnih slika mekog tkiva magnetska rezonanca je nezamjenjiva metoda dobivanja medicinskih slika. Ovaj rad će opisati proces dobivanja slika magnetskom rezonancom, te istražiti fastMRI projekt. Bit će izvedena rekonstrukcija MRI slika mozga koristeći neke od modela koji se nalaze u fastMRI biblioteci. Objasnit će se rad modela i međusobno usporediti rekonstrukcije.

2 Pristup

2.1 Magnetska rezonanca (MRI)

Magnetska rezonanca mozga (MRI) je važna metoda koja pruža detaljan prikaz unutrašnje strukture mozga, što može biti od velike koristi u medicinskoj dijagnostici i praćenju različitih neuroloških poremećaja. Služi za dijagnostiku različitih neuroloških poremećaja poput tumora mozga, multiple skleroze, moždanog udara, epilepsije i drugih bolesti. Uz to se koristi i za praćenje napredovanja bolesti i planiranje kirurških zahvata. Potpuno je bezbolna metoda koja za stvaranje slike koristi jako magnetsko polje i radiovalove, a time nema štetnog ionizirajućeg zračenja i nuspojava. Postupak dobivanja slike traje od 15 do 90 minuta, a tijekom postupka osoba mora mirno ležati unutar stroja. Najmanje kretnje uzrokuju šum i artefakte. S obzirom na trajanje postupka, iskustvo može biti neudobno i klaustrofobično. Dugo trajanje postupka ima i posljedice na povećanje cijene snimanja jer je potrebno više vremena po osobi. No, sposobnost detaljnog slikanja mekog tkiva nije zamjenjiva metodama poput CT snimanja i rendgenskog snimanja. Time, smanjenje trajanja slikanja postupkom magnetske rezonancije je poželjno [3].

Magnetska rezonancija se temelji na fizikalnoj pojavi nuklearne magnetske rezonancije. U toj pojavi jezgre određenih atoma (na primjer vodikovih jezgri u magnetskoj rezonanciji mozga) pokazuju sposobnost upijanja i odašiljanja elektromagnetske energije prilikom stavljanja u magnetsko polje. Ponašaju se kao mali štapićasti magneti, te ako se nalaze u magnetskom polju oni će se poravnati s njim. Zatim, stroj za magnetsku rezonanciju odašilje u njih elektromagnetski puls radio frekvencije, te ih time izbjiga iz poravnanja s magnetskim poljem. Ovdje djelovanje nuklearne magnetske rezonancije dolazi u utjecaj. Jezgre atoma će se rotirati i time odašiljati radio signal. No, nakon određenog vremena njihova će rotacija stati, te će se ponovno poravnati s magnetskim poljem. Vrijeme da se jezgra atoma prestane rotirati, vrijeme da se ponovno poravna s magnetskim poljem i količina energije koja je ispuštena ovise o kemijskom sastavu molekula. S obzirom na to je moguće razaznati razliku između različitih vrsta tkiva. Postupak magnetske rezonance uzorkuje područje koje snimamo u Fourierovom prostoru, koji je također poznat kao k-prostor. Uporabom inverzne Diskrete Fourierove Transformacije (DFT) (Formula 1 nad k-prostorom slike y dobivamo rekonstruiranu sliku m [9].

$$\hat{m} = \mathcal{F}^{-1}(y) \quad (1)$$

Kvaliteta slike se određuje trima karakteristikama. Omjerom snage signala i snage šuma (SNR), oblikom piksela (*point spread function*) i artefaktima. Ako je snaga šuma visoka, dolazi do diskoloracije konačne slike. Oblik piksela bi trebao biti samo jedan piksel, no ako funkcija širenja sadrži više frekvencija doći će do zamućenja piksela. Artefakti nastaju kada su signali povezani uz piksele kojima ne pripadaju. To stvara preklapanja slike i nastanak nepostojećih oblika na slikama. Ako je kvaliteta slike niska, može doći do skrivanja bitnih obilježja na slici što može dovesti do pogrešne dijagnoze, ili u najgorem slučaju slike koju nije moguće iskoristiti.

2.2 Tehnike rekonstrukcije

Uvođenjem paralelnog slikanja u 90-im godinama prošlog stoljeća skraćena je duljina trajanja postupka. Svaka dodana zavojnica slika zasebnu sliku u k-prostoru. Rekonstruirana slika y_i , zavojnice i od n_c dobiva se iz (Formula 2):

$$y_i = \mathcal{F}(S_i m) + noise = g_i * \mathcal{F}(m) + noise \quad (2)$$

gdje je S_i osjetljivost zavojnice, a g_i njena Fourierova transformacija [9]. Uvođenjem komprimirajuće osjetljivosti (engl. *compressed sensing (CS)*) doprinijelo je napretku u smanjenju vremena snimanja magnetske rezonance. *Compressed sensing* tehnike ubrzavaju slikanje uzorkovanjem manje količine podataka nego klasičnim metodama. No zbog kršenja Nyquist-Shannonovog teorema uzorkovanja, ono dovodi do nastanka artefakta. Artefakti se prilikom rekonstrukcije moraju ukloniti, a to se postiže uporabom prethodnog znanja tijekom re-

konstrukcije. ESPIRiT je pristup koji povezuje paralelno slikanje i CS. U slikanju s više zavojnica služi za procjenu osjetljivosti zavojnica i za izvođenje rekonstrukcije slika u kombinaciji s CS korištenjem regularizacije ukupne varijacije.

Najnoviji pokušaji rekonstrukcije se izvode metodama dubokog učenja modela. Kretanje u tom smjeru je potaknuto objavljanjem javno dostupnog fastMRI skupa podataka.

2.3 fastMRI

fastMRI je zajednički istraživački projekt između *Facebook AI Research*-a i *NYU Langone Health*-a. Cilj projekta je razvijanje bržih postupaka slikanja magnetskom rezonancom uporabom tehnika dubokog učenja. Projekt je javan i sadrži velike skupove podataka magnetske rezonance koljena i mozga koji se mogu koristiti za treniranje i testiranje modela dubokog učenja za bržu rekonstrukciju slika.

2.3.1 fastMRI dataset

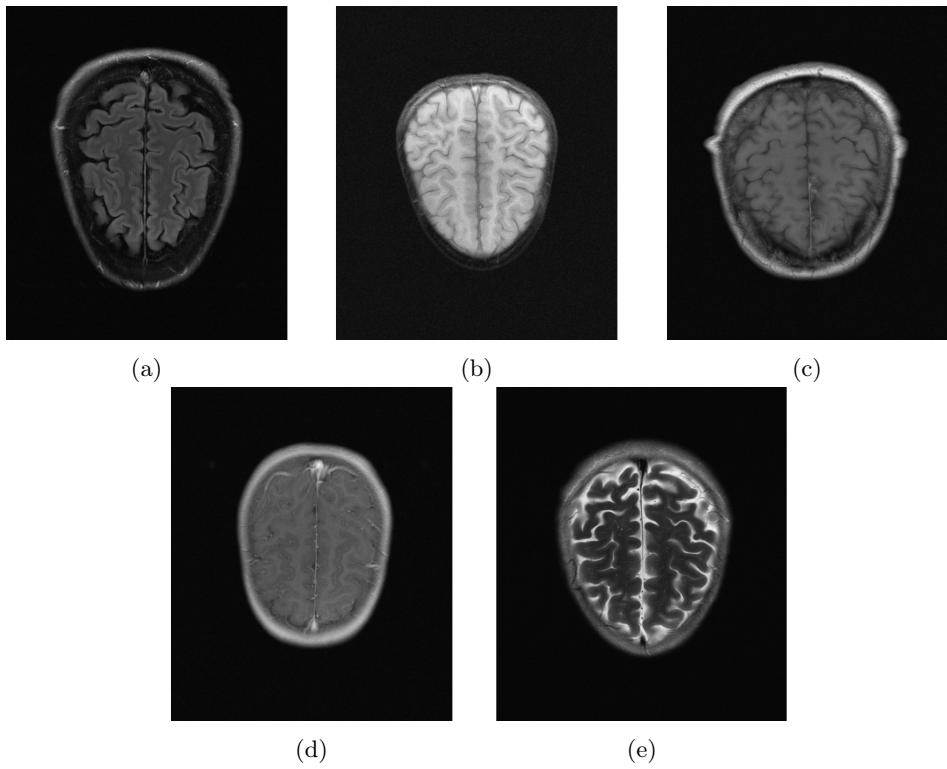
fastMRI skup podataka je javno objavljen i sastoji se od četiri tipa snimaka mozga i koljena:

- Neprocesiranih snimaka k-prostora snimljenih metodama paralelnog snimanja.
- Emuliranih podataka k-prostora snimaka jednom zavojnicom.
- (*Ground-truth*) Rekonstrukcija potpuno uzorkovanih slika dobivenih paralelnim snimanjem.
- DICOM (*Digital Imaging and Communications in Medicine*) slika.

Podatci su predviđeni kako bi omogućili dva različita zadatka:

- Rekonstrukciju slika uzorkovanih jednom zavojnicom.
- Rekonstrukciju slika uzorkovanih metodom paralelnog slikanja.

Za svaki izazov objavljeni su službeni podskupovi za trening, validaciju, test i izazova. Svi podatci su anonimizirani. Sveukupno je 1594 neprocesiranih snimaka k-prostora koljena dobivenih s više zavojnica, 6970 slika k-prostora mozga dobivenih s više zavojnica. Podatci za izazov rekonstrukcije slika uzorkovanih jednom zavojnicom dobiveni su emulacijom podataka iz k-prostora slika dobivenih metodom s više zavojnica. 10000 DICOM slika mozga i koljena dobivenih MRI slikanjem. Podatci su dobiveni različitim protokolima prikupljanja. Kod slika koljena koristi se CORPD ili CORPDF protokol, dok se za slike mozga koristi AXFLAIR, AXT1, AXT1PRE, AXT1POST ili AXT2 protokol (Slika 1) [2] [9]. Navedeni protokoli imaju različite vremenske duljine jeka i inverzije, parametri kojima se utječe na kvalitetu slike i njen kontrast.



Slika 1: Prikaz slika dobivenih a) AXFLAIR, b) AXT1, c) AXT1PRE, d) AXT1POST i e) AXT2 tehnikama.

2.3.2 fastMRI biblioteka

Uz dataset, fastMRI također pruža *open-source* set alata za rad s podatcima iz datasetsa i implementaciju modela dubokog učenja za rekonstrukciju slika. Oni sadrže Python biblioteke za učitavanje podataka, pretprocesiranje i evaluaciju podataka, uz prije trenirane modele i tehnike za rekonstrukciju. Prije trenirani modeli i tehnike koje se nalaze u biblioteci su *Compressed Sensing*, *Zero-Filled*, U-net i Varnet modeli, uz njih sadrži i njihov kod.

2.3.3 fastMRI repozitorij

Kako je projekt javno dostupan, njegov kod i upute za uporabu se nalaze na GitHub repozitoriju [9]. Repozitorij sadrži kod i dokumentaciju za funkcije koje se nalaze u biblioteci, upute za instalaciju potrebnih programskih ovisnosti i okruženja, skripte za pokretanje metoda rekonstrukcije i popis literature vezan uz rad.

3 Opis rada modela

U fastMRI biblioteci se nalaze modeli poput U-Net, VarNet, Zero-Filled, Compressed Sensing i Adaptive VarNet. Zero-Filled, Compressed Sensing i U-Net su osnovni modeli, a VarNet i Adaptive VarNet su mreže rađene specifično za fastMRI zadatak. Za Zero-Filled, Compressed Sensing, U-Net i VarNet modele postoji kod za preuzimanje i uporabu već istreniranih modela. Zbog izrazito visokih hardverskih zahtjeva treniranja modela koristit će se samo već istrenirani dostupni modeli. Postupak izvođenja modela nad podatcima pokreće se pokretanjem za to namijenjenim skripti koje se nalaze u fastMRI repozitoriju [9].

3.1 *Zero-Filled* metoda

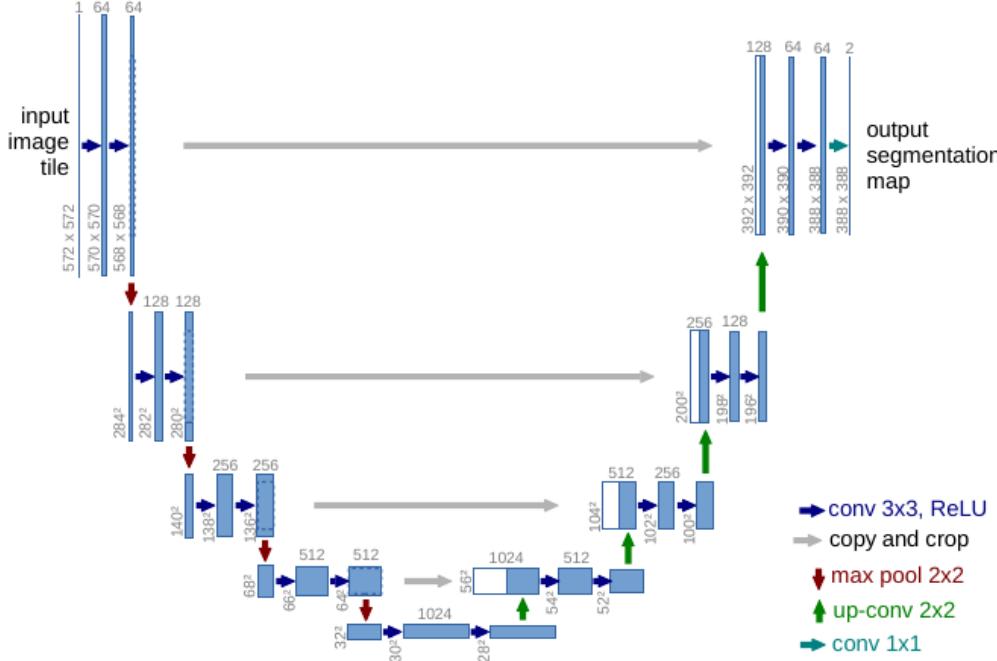
Zero-Filled ili metoda popunjavanja nulama postavlja nulu na mjesto svih neuzorkovanih podataka u k-prostoru. Zatim primjenjuje dvodimenzionalnu Inverznu Fourierovu Transformaciju na rezultat i računa konačnu vrijednost [9].

3.2 *Compressed Sensing* metoda

Compressed sensing (CS) je matematička tehnika koja omogućava rekonstrukciju signala ili slike iz manje informacija nego što je inače potrebno. Implementacija se temelji na ESPIRiT [8] radu. Također koristi BART (engl. *The Berekeley Advanced Reconstruction Toolbox* besplatni i *open-source* set alata za rekonstrukciju slika magnetske rezonance. Pruža česte operacije na multi dimenzionalnim poljima, Fourierove i *wavelet* transformacije, kao i implementacije iterativnih optimizacijskih algoritama. Alati za komandnu liniju pružaju direktni pristup rekonstrukcijskim algoritmima za paralelno slikanje i *compressed sensing* [4].

3.3 U-Net model

Uobičajena uporaba konvolucijskih mreža je klasifikacijskim zadatcima, gdje je izlaz na sliku jedinstvena klasa. No, u mnogim zadatcima, pogotovo u biomedicinskoj obradi slika, je potrebno postići lokalizaciju. Odnosno, dodjeljivanje klase svakom pikselu slike [5]. U ovom radu se koristi već istreniran U-Net model dostupan u fastMRI biblioteci. Taj model je namijenjen rekonstrukciji slika uzorkovanih s jednom zavojnicom. Za uporabu nad slikama uzorkovanimi s više zavojnica potrebno izvršiti *zero-fill* metodu nad slikom svake zavojnice. *Zero-fill* metoda na mjesto svih neizmjerjenih podataka u k-prostoru stavlja nule, a zatim primjenjuje Inverznu Fourierovu Transformaciju. Rezultat se centrirano reže kako bi se uklonilo prelijevanje očitanja i faze. Nakon primjene *zero-fill* metode, slike zavojnica se povezuju koristeći algoritam korijena zbroja kvadrata. Model je treniran kako bi minimizirao gubitak srednje apsolutne pogreške (RMSE) [9].



Slika 2: U-Net arhitektura.

Model sadrži dva duboka konvolucijska mrežna puta (Slika 2). Prvi dio je dio sažimanja uzorka, a zatim ide dio povećavanja uzorka. Put sažimanja se sastoji od blokova s dvije 3x3 konvolucije, svaku konvoluciju prati normalizacija po instancama i ReLU (engl. Rectified Linear Unit) aktivacijska funkcija. Blokovi se izmjenjuju operacijom smanjivanja uzorka (engl. down-sampling) koja se sastoji od slojeva maksimalnog uzorkovanja (engl. max-pooling) s korakom dva. Time se svaka prostorna dimenzija prepolovljuje. Na putu povećavanja uzorka (engl. up-sampling) nalaze se blokovi slične arhitekture kao na putu sažimanja, a blokovi se izmjenjuju operacijama povećavanja rezolucije prethodnog bloka. Put povećavanja uzorka povezan je s putem sažimanja s preskočnim (engl. skip) vezama. Put sažimanja omogućava hvatanje konteksta i otkriva što je na slici dok put širenja otkriva gdje se to nalazi na slici. Kako bi lokalizacija bolje funkcionalala, značajke visoke rezolucije iz puta sažimanja se preskočnim vezama povezuju s izlazima s puta povećanja uzorka. S informacijom iz preskočnih veza dobiva se precizniji izlaz iz bloka. Na kraju puta povećavanja uzorka nalaze se 1x1 konvolucije kako bi se smanjio broj kanala na jedan bez promjene prostorne rezolucije. Kako bi se predvidjeli rubni pikseli ulazne slike, primjenjuje se tehnika zrcaljenja za popunjavanje nedostajućih podataka.

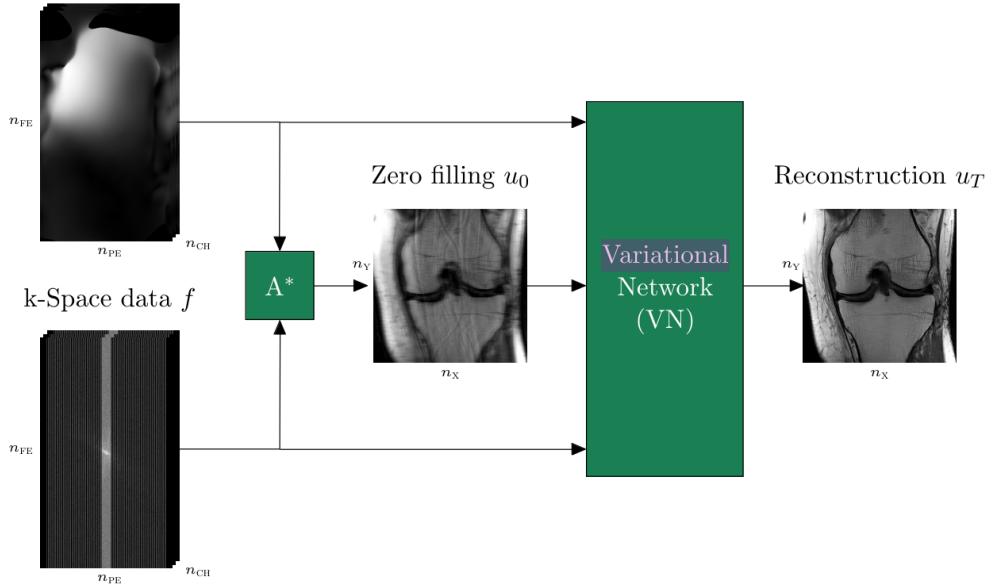
Istrenirani model koji fastMRI biblioteka pruža je treniran na 973 slike iz trening seta uporabom RMSProp algoritma. Prvih 40 epoha stopa učenja je 0.001, a zatim se množi s 0.1 i trenira se još 10 epoha.

3.4 End-to-End VarNet model

Varijacijska mreža (VN) opisana u *Learning a Variational Network for Reconstruction of Accelerated MRI Data* [1] dizajnirana je da nauči kompletni proces rekonstrukcije kompleksnih podataka korištenih u MRI rekonstrukciji. Sastoji se od seta nelinearnih transformacija koje su korištene kako bi zapisale ulazne podatke u manje dimenzionalnom latentnom prostoru, prilikom očuvanja važnih informacija o ulazu. Latentni prostor je niže dimenzionalni prostor koji zapisuje strukturu ulaznih podataka. Koristi varijacijsku inferenciju kako bi naučila reprezentirati latentni prostor. VarNet je dizajniran za obradu medicinskih slika, a osobito za rekonstrukciju slika magnetske rezonance. Arhitektura klasične VarNet mreže (Slika 3) se sastoji od zero-fill rješenja koje je izračunato iz poduzorkovanog k-prostora uporabom operatora A^* . A^* operator aplicira i mape osjetljivosti zavojnica. Zatim VarNet mreži predajemo zero-fill, mape osjetljivosti zavojnica i poduzorkovan k-prostor kako

bi dobili rekonstrukciju. VarNet mreža se sastoji od T koraka gradijentnog spusta. Kako se radi o slikama kompleksnih vrijednosti, treniramo odvojene filtre za realnu i kompleksnu ravninu koje nelinearna aktivacijska funkcija kombinira [1].

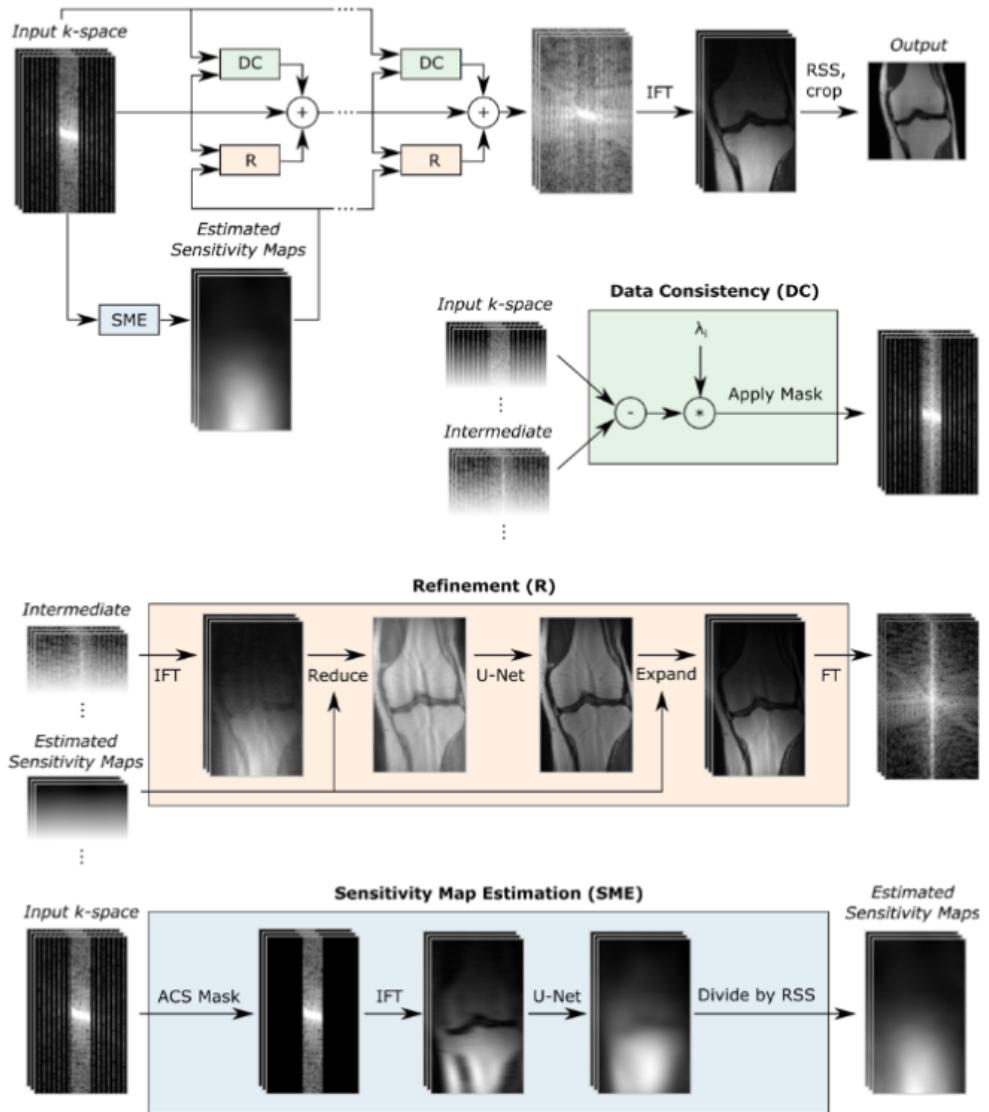
Sensitivity maps



Slika 3: VarNet arhitektura.

End-to-End Variational Network proširuje klasičnu VarNet mrežu treniranjem *end-to-end*. Što znači da cijeli postupak rekonstrukcije slike, od sirovih podataka do konačne rekonstrukcije slike, obavlja unutar mreže.

Ako je k_0 vektor k-prostora više zavojnica, kao u VarNet-u, model uzima k_0 kao ulaz i primjenjuje niz koraka podešavanja istog oblika. Te korake nazivamo kaskadama. Za razliku od klasičnog VarNeta, ovaj model koristi k-prostor kao međukorake, umjesto slika u prostoru. Sastoje se od operatara ekspanzije i sažimanja. Operator ekspanzije uzima sliku i mape osjetljivosti kao ulaz i računa odgovarajuću sliku svake zavojnice u idealnom slučaju bez šuma. Operator sažimanja kombinira slike zavojnica. Svaka kaskada u modelu primjenjuje korak podešavanja. Zato što se CNN primjenjuje nakon kombiniranja svih zavojnica, ista mreža se može koristiti za MRI s različitim brojem zavojnica. Ova mreža koristi U-Net za CNN. Model je treniran s 30 milijuna parametara koristeći Adam optimizaciju sa stopom učenja od 0.0003 za 50 epoha, bez upotrebe tehnika regularizacije ili augmentacije podataka [7].



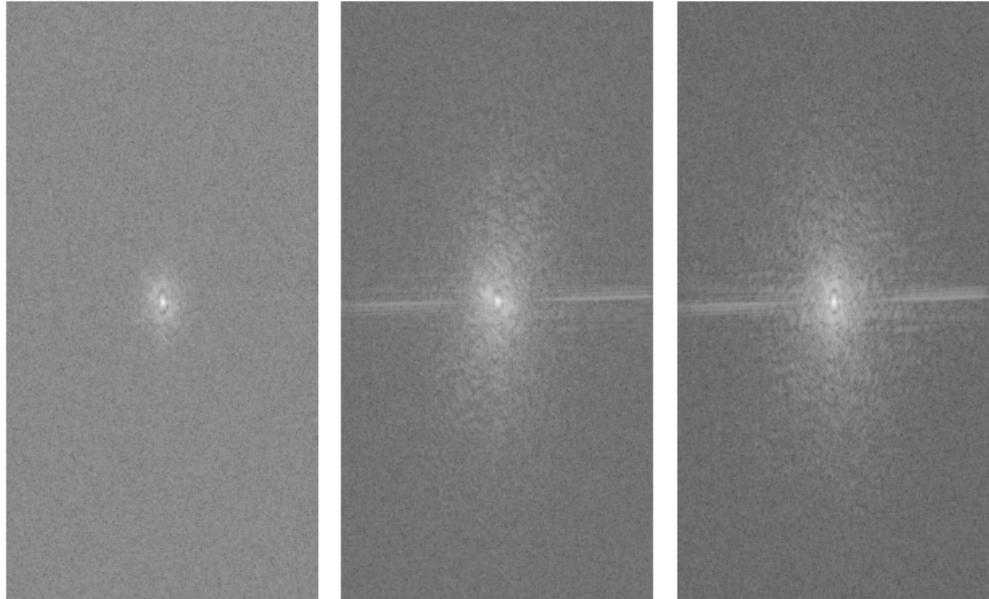
Slika 4: *End-to-End Variational Network* arhitektura.

4 Testiranje

4.1 Prikaz podataka

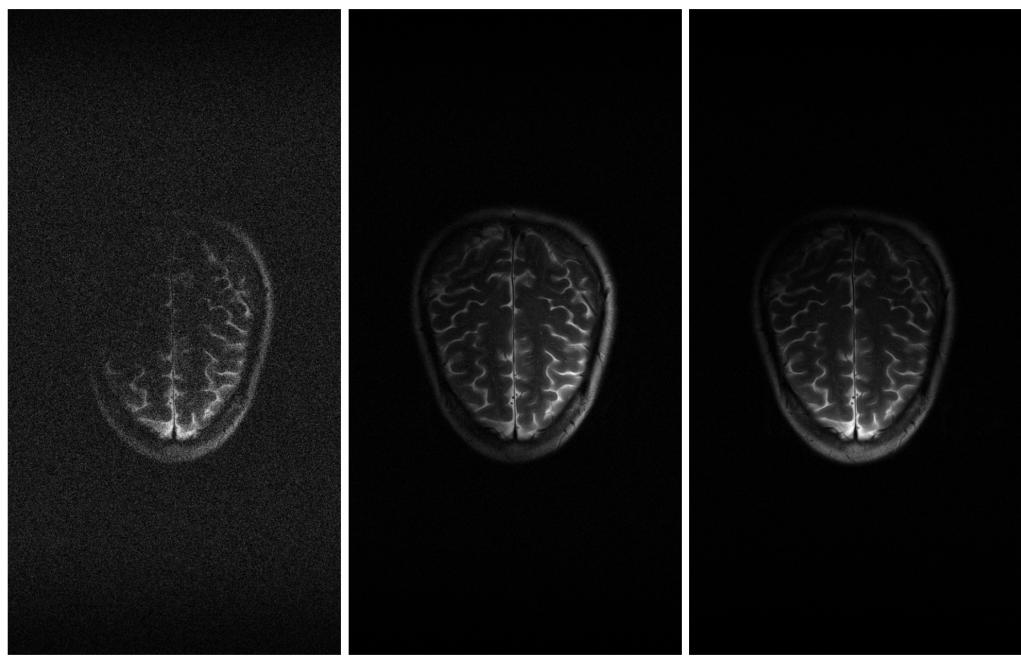
U svrhe testiranja preuzeti su validacijski i testni skupovi podataka. Trening skup podataka nije korišten zbog svoje veličine (približno 1100GB). Slike su zapisane u HDF5 (*The Hierarchical Data Format version 5*) formatu i bila je potrebna uporaba dodatne h5py biblioteke kako bi se mogle čitati. HDF5 format je *open-source* format koji podržava velike, kompleksne i heterogene podatke. koristi strukturu direktorija podataka koji omogućuje strukturiranu organizaciju podataka unutar datoteke [6]. Uz nju i fastMRI, korištene su numpy i matplotlib biblioteke.

HDF5 format sadrži ključeve i atributе. Ključevi služe za identificiranje grupa i setova podataka, dok atributi predstavljaju meta podatke vezane uz podatke. Validacijski podatci sadrže "ismrmrd_header", "kspace" i "reconstruction_rss" ključeve, te "aquisition", "max", "norm" i "patient_id" atributе. Podatci o k-prostoru se nalaze unutar "kspace" ključa i zapisani su u matričnom obliku. Kako bi prikazali sloj k-prostora potrebno je logaritmirati njegovu absolutnu vrijednost.

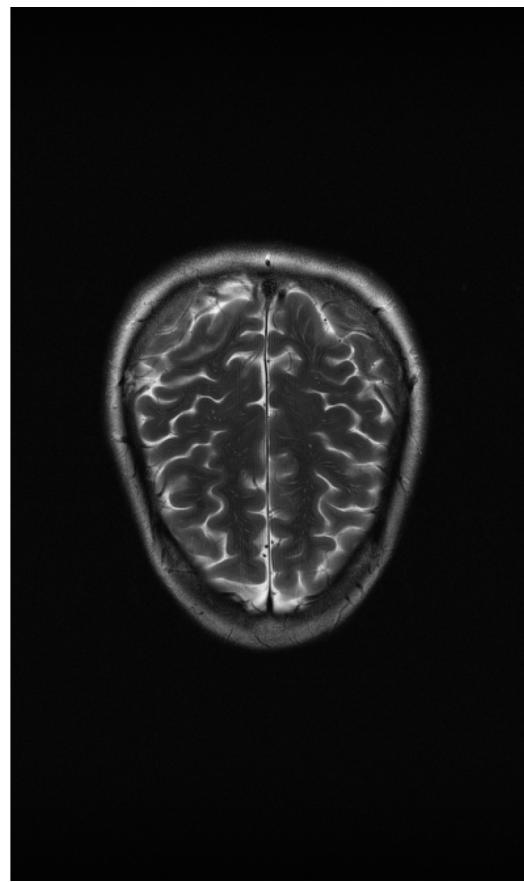


Slika 5: K-prostor desetog sloja i prve, osme i četrnaeste zavojnice.

Za prikaz prave slike potrebno je nad k-prostorom izvršiti inverznu Fourierovu transformaciju. Nakon toga je potrebno izračunati njegovu absolutnu vrijednost. Možemo vidjeti da se svaka slika zavojnice fokusira na drugu regiju. Slike zavojnica je moguće spojiti uporabom korijena zbroja kvadrata.



Slika 6: Prikaz slike desetog sloja i prve, osme i četrnaeste zavojnice.

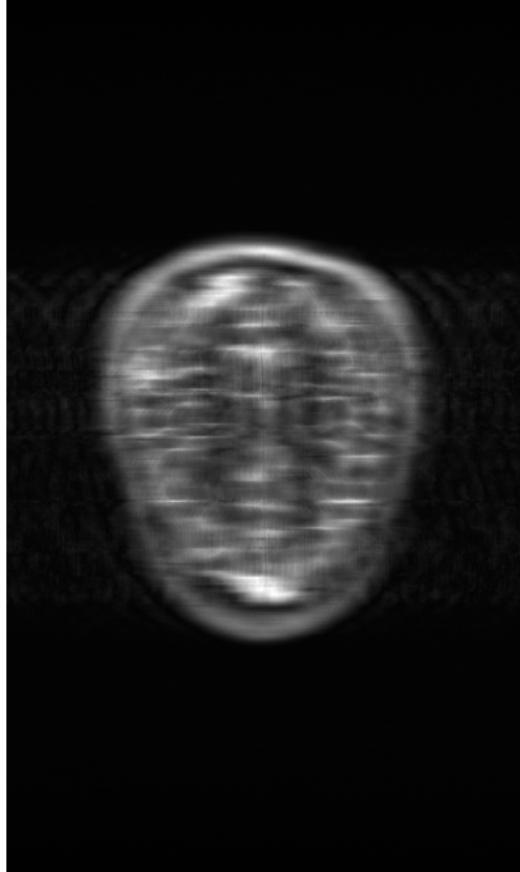


Slika 7: Prikaz potpuno uzorkovane slike.

4.2 Testiranje modela

4.2.1 Simulacija šuma

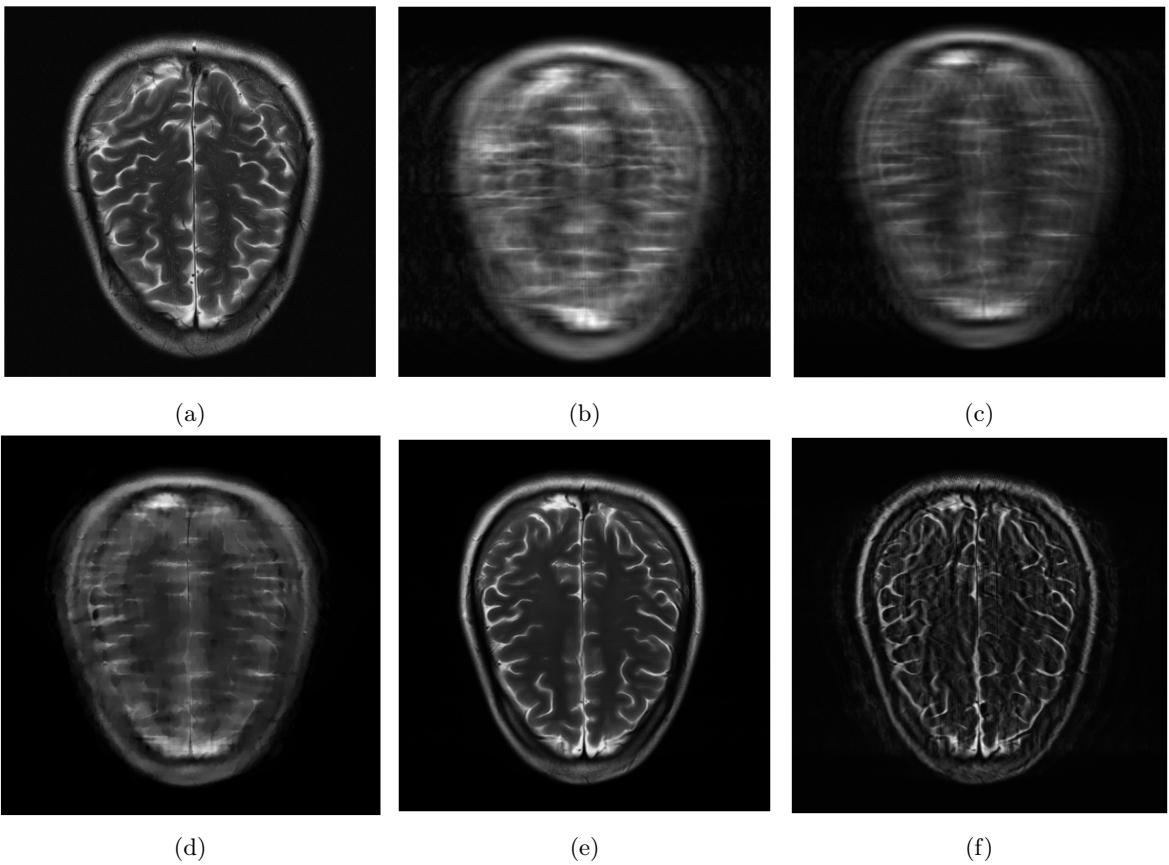
S obzirom na to da su validacijske slike potpuno uzorkovane, ako ih provučemo kroz model za rekonstrukciju nećemo dobiti značajne rezultate. Iz tog razloga simuliramo šum na njima. Šum simuliramo stvaranjem maske i postavljanjem te maske na k-prostor. Masku stvaramo s `RandomMaskFunc()` funkcijom iz fastMRI biblioteke. Navodimo stupanj akceleracije i centralnih frakcija. Nakon provlačenja podataka kroz masku, slika desetog sloja prikazana je na slici, a prikaz k-prostora na slici.



Slika 8: Prikaz slike s nanešenim šumom.

4.2.2 Usporedba rezultata

Kada slike provrtimo kroz model, one vraćaju rezultat isto u H5DF formatu. Rekonstrukcije su prikazane na sljedećim slikama. Možemo primjetiti da su rezultati poprilično različiti. Kod *zero-fill* tehnike nemamo nekih velikih razlika od originalne komprimirane slike. Kod *compressed sensing* tehnike možemo uočiti već neke pokušaje nadopunjavanja nepostojećih podataka. Slika je i dalje mutna i ima efekt vodenih boja. VarNet metoda donosi već bolje rezultate. Ako zanemarimo preslikavanje, slika je oštija naspram prošle i prikazuje više detalja. No baš zbog tog preslikavanja nije moguće shvatiti te detalje kao ispravne jer ih je teško međusobno razlikovati. U-Net metoda ima najbolje rezultate. Slika je i dalje malo mutna, no detalji su uočljiviji i ne preslikavaju se međusobno.

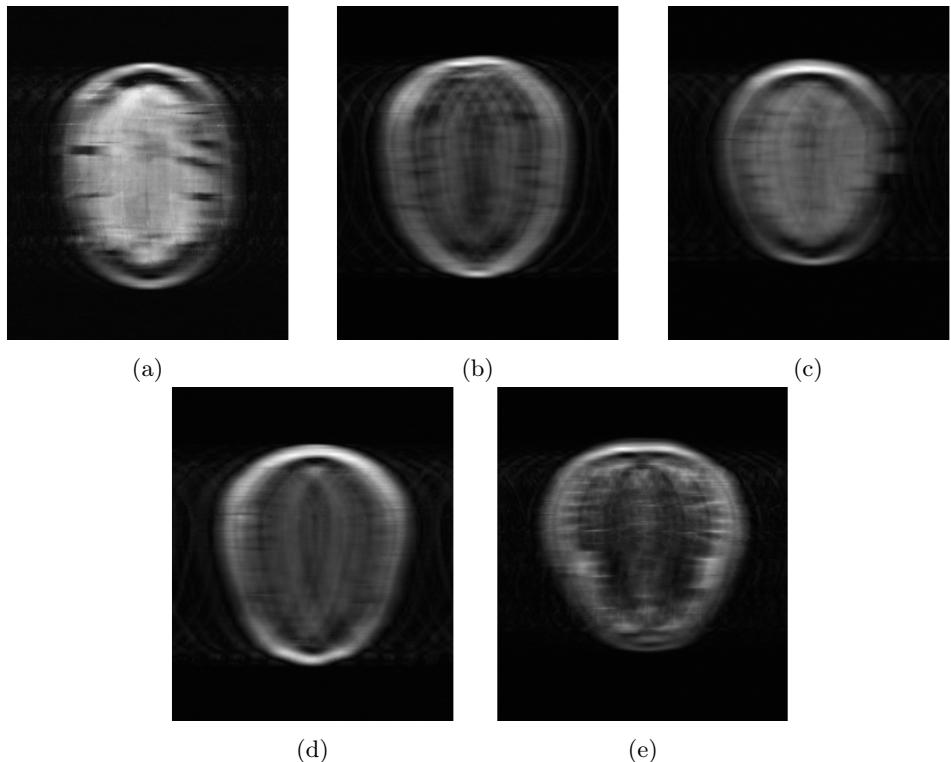


Slika 9: Pod (a) se nalazi izvorna slika, pod (b) se nalazi slika nakon što je šum nanesen, pod (c) je prikaz slike nakon primjene *zero-fill* tehnike, pod (d) je prikaz slike nakon primjene *compressed-sensing* tehnike, pod (e) je prikaz slike nakon primjene VarNet modela, a pod (f) je prikaz slike nakon primjene U-Net modela.

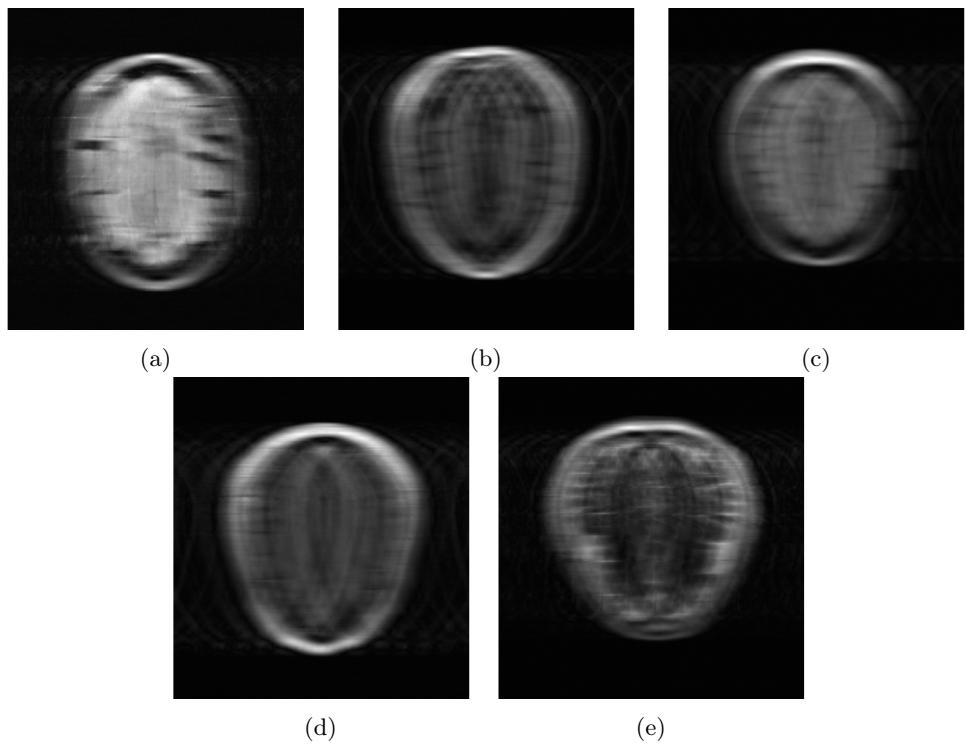
Kada usporedimo rekonstrukcije s originalnom slikom, uočavamo nedostatak detalja čak i kod metoda s boljim rezultatima. Kad stavimo slike jednu pored druge nedostatci su još neuočljiviji. Uz preslikavanje, uočljiv je i nedostatak detalja.

4.2.3 Prikaz rezultata nad testnim podatcima

U prethodnom odlomku su prikazani rezultati modela nad potpuno uzorkovanim podatcima kojima je smanjena kvaliteta. Na sljedećim slikama prikazujemo rekonstrukcije nad podatcima koji su izvorno loše kvalitete. Odrađene su rekonstrukcije nad sva četiri tipa protokola prikupljanja podataka. Na slici 9 vidimo prikaze svih tehnika. Slike su birane tako da razina šuma među njima bude približno jednaka. Kao i u prethodnim rezultatima na slici 9 primjena *zero-fill* metode nije dovela do značajnih rezultata.

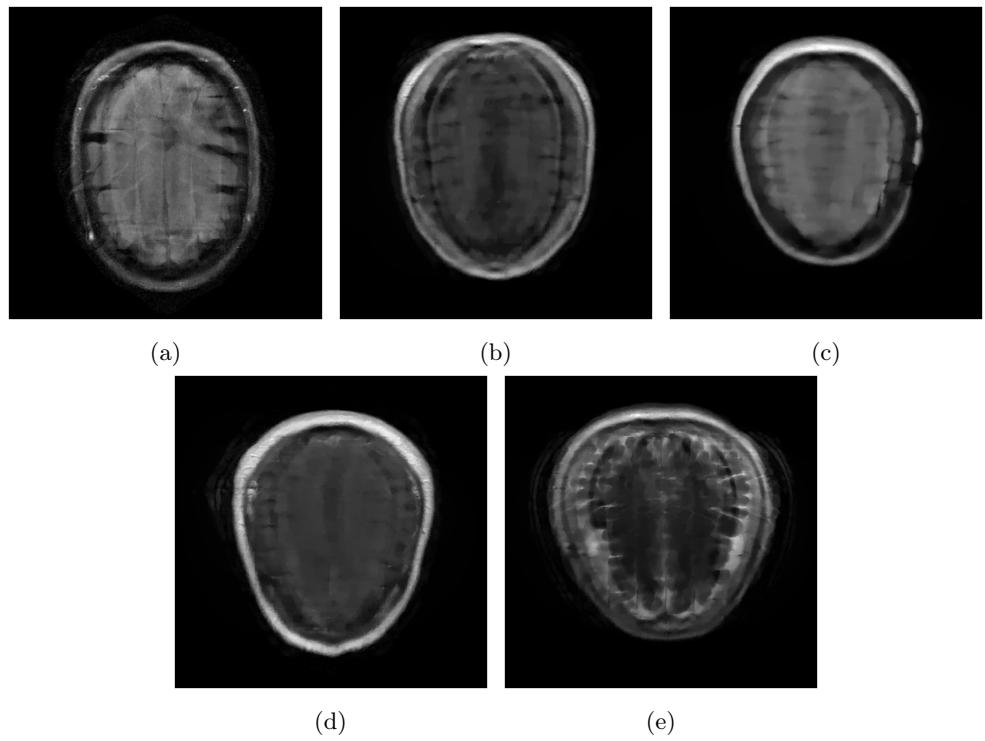


Slika 10: Prikaz testnih slika dobivenih a) AXFLAIR, b) AXT1, c) AXT1PRE, d) AXT1POST i e) AXT2 protokolima.

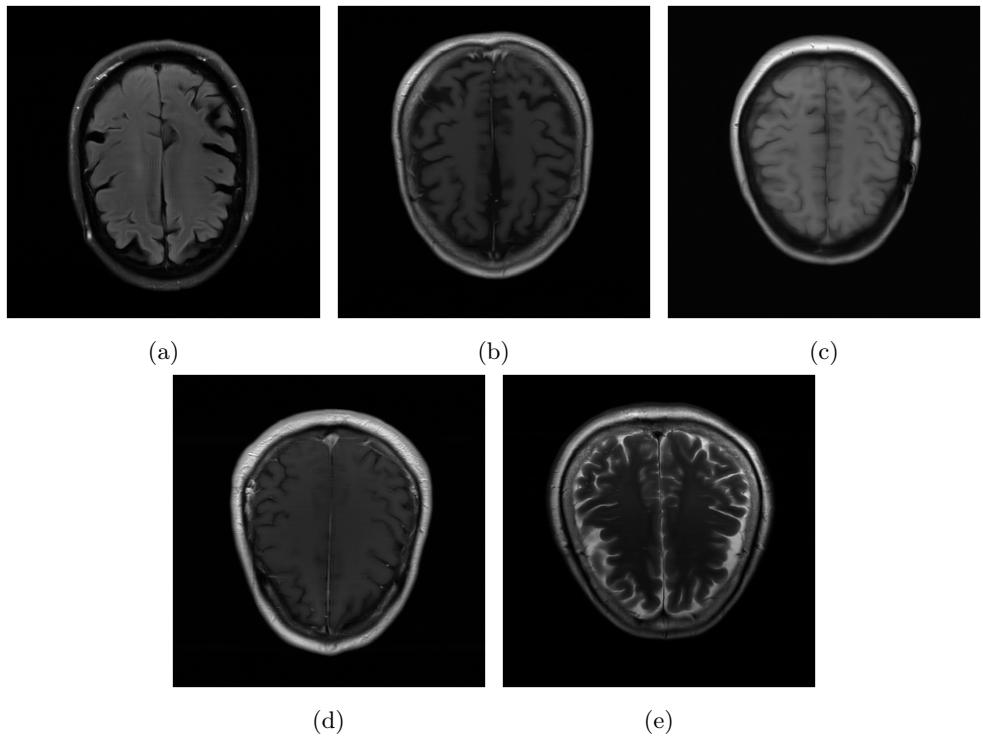


Slika 11: Prikaz testnih slika na kojima je primjenjena *zero-fill* tehnika. a) AXFLAIR, b) AXT1, c) AXT1PRE, d) AXT1POST i d) AXT2.

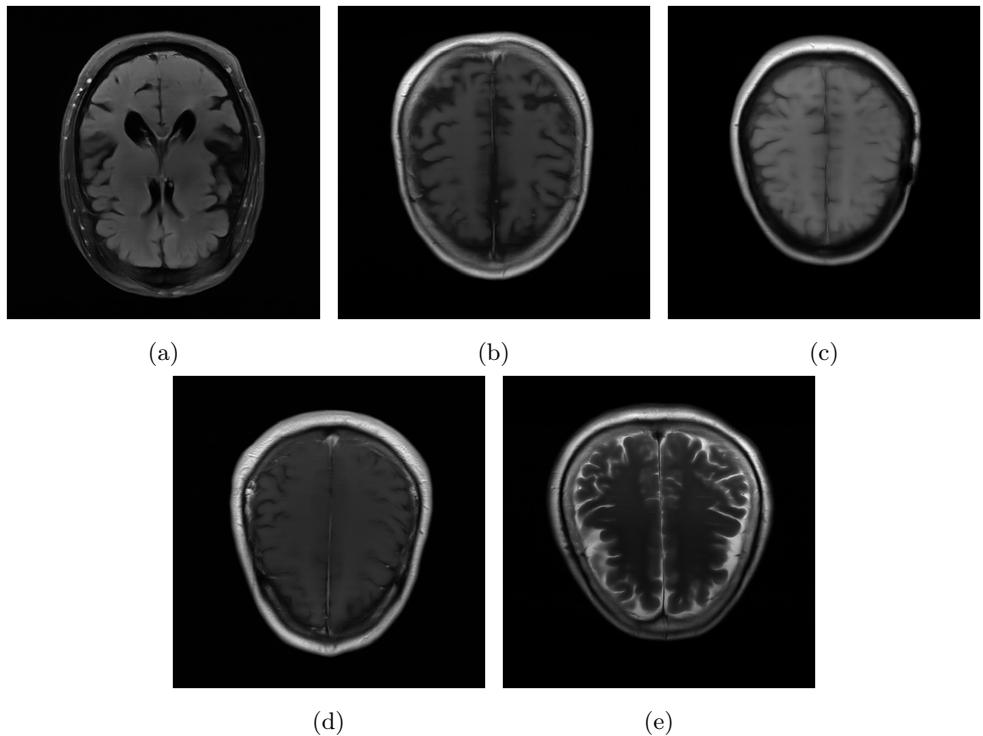
Usporedbom rezultata (Slika 12) dobivenih *compressed sensing* metodom sa slikom 9 imamo slične rezultate. Slike su nešto bolje kvalitete, no i dalje izrazito mutne. U-Net model (Slike 14) zato daje očekivane rezultate koji su usporedivi onima sa slike 9. Do prve veće razlike dolazimo kod rezultata VarNet modela. Testni podatci obrađeni VarNet modelom (Slika 13 daju vidljivo bolje rezultate. Nema preslikavanja slike kao na slici 9. Razlog tome može biti dodatni šum centralnih frakcija koji je nanesen na podatke na slici 9.



Slika 12: Prikaz testnih slika na kojima je primjenjena *compressed sensing* tehnika. a) AXFLAIR, b) AXT1, c) AXT1PRE, d) AXT1POST i d) AXT2.



Slika 13: Prikaz testnih slika na kojima je primijenjena VarNet model. a) AXFLAIR, b) AXT1, c) AXT1PRE, d) AXT1POST i d) AXT2.



Slika 14: Prikaz testnih slika na kojima je primijenjen U-Net model. a) AXFLAIR, b) AXT1, c) AXT1PRE, d) AXT1POST i d) AXT2.

U konačnici dobiveni rezultati rekonstrukcija pokazuju vidljivo poboljšanje kvalitete slike. Pregledom slika VarNet metoda daje nešto bolje rezultate nego U-Net, a oba modela daju znatno bolje rezultate od ostalih tehnika. Što se tiče kliničke točnosti i uporabljivosti rekonstrukcija, zaključak nije moguće donijeti bez suradnje sa stručnjacima za medicinsku dijagnostiku.

5 Zaključak

Uspješna rekonstrukcija slika magnetske rezonance mozga kompleksan je i zahtjevan zadatak. fastMRI Python biblioteka pruža funkcije korisne za rad s rekonstrukcijom magnetske rezonance. Uz to su dostupne već gotove tehnike za rekonstrukciju, poput *zero-fill* i *compressed sensing* tehnika, i istrenirani modeli, U-Net i VarNet, te kod za pokretanje tih modela. U ovom radu prikazujemo rezultate dobivene uporabom prethodno navedenih tehnika i modela. Prvo je na potpuno uzorkovanu sliku postavljen šum, te su zatim nad slikom sa šumom odrađene rekonstrukcije. Ovo smo radili kako bi mogli usporediti rezultate s potpuno uzorkovanom rekonstrukcijom i time imati lako vidljive sve karakteristike rekonstrukcija. Dobiveni rezultati kod U-Net i VarNet modela prikazuju čišće slike, no usporedbom s izvornom slikom uočava se manjak detalja. Zatim su učitane testne slike svih pet metoda prikupljanja podataka i nad njima su odrađene rekonstrukcije. Rezultati također daju kvalitetnije i oštrienje slike kod U-Net i VarNet modela, no nije moguće izvući potpuni zaključak iz razloga što nemamo usporedbu kao u prethodnom primjeru. Uz to, zaključak o kliničkoj valjanosti dobivenih rezultata nije moguće ostvariti bez savjetovanja sa stručnjakom iz područja medicinske dijagnostike. No, i dalje kvaliteta slike je vidljivo veća, te pristup rekonstrukciji metodama strojnog učenja ima potencijal za rješenje problema manje uzorkovanih slika u budućnosti. Veliki problem u razvoju modela za dani zadatak su hardverski zahtjevi, jer su za treniranje su potrebni dani i izrazito visoka računalna snaga koja nije svima dostupna.

6 Literatura

Literatura

- [1] Kerstin Hammernik i dr. *Learning a Variational Network for Reconstruction of Accelerated MRI Data*. 2017. arXiv: 1704.00447 [cs.CV].
- [2] Florian Knoll i dr. “fastMRI: A Publicly Available Raw k-Space and DICOM Dataset of Knee Images for Accelerated MR Image Reconstruction Using Machine Learning”. *Radiology: Artificial Intelligence* 2.1 (2020.), e190007.
- [3] *Magnetic Resonance Imaging (MRI)*. National Institute of Biomedical Imaging and Bioengineering (NI-BIB). Retrieved from <https://www.nibib.nih.gov/science-education/science-topics/magnetic-resonance-imaging-mri>.
- [4] *MRI Reconstruction Toolbox (BART)*. <https://mrirecon.github.io/bart/index.html>. Accessed: April 17, 2023.
- [5] Olaf Ronneberger, Philipp Fischer i Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015. arXiv: 1505.04597 [cs.CV].
- [6] NEON Science. *About HDF5*. <https://www.neonscience.org/resources/learning-hub/tutorials/about-hdf5>. Accessed April 18, 2023. n.d.
- [7] Anuroop Sriram i dr. *End-to-End Variational Networks for Accelerated MRI Reconstruction*. 2020. arXiv: 2004.06688 [eess.IV].
- [8] Martin Uecker i dr. “ESPIRiT—an eigenvalue approach to autocalibrating parallel MRI: Where SENSE meets GRAPPA”. *Magnetic Resonance in Medicine* 71.3 (2014.), str. 990–1001. DOI: <https://doi.org/10.1002/mrm.24751>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1002/mrm.24751>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/mrm.24751>.
- [9] Jure Zbontar i dr. *fastMRI: An Open Dataset and Benchmarks for Accelerated MRI*. 2019. arXiv: 1811.08839 [cs.CV].